

银行客户星级与信用等级评估预测实验文档

一、实验基本信息

1.1 实验背景

客户星级（star_level）与信用等级（credit_level）是银行开展信贷服务、客户分层运营、业务权限审批的核心参考指标。其中客户星级与用户存款资产情况强相关，用于衡量客户资产价值与客户层级；信用等级与用户贷款、贷记卡使用、还款履约行为强相关，用于评估客户信贷风险。

本次实验数据集包含客户星级表（pri_star_info）、客户信用等级表（pri_credit_info），数据中标签值为-1的样本为待预测样本，其余已有标签样本可用于模型训练与验证。本次实验通过**机器学习建模+自定义行业规则**两种方式，实现客户星级、信用等级的预测评估，并将最优模型应用于测试集完成批量预测。

1.2 实验目标

- 完成银行客户多源数据的整合、清洗、预处理与特征工程，构建适配星级、信用等级预测的特征体系。
- 分别搭建机器学习模型与自定义行业规则模型，实现客户星级、信用等级多分类预测。
- 对比不同模型性能，筛选最优模型，在测试集上完成待评估客户（标签=-1）的星级与信用等级预测。
- 完成模型评估、结果分析，形成完整的银行客户风险与价值评估方案。

1.3 实验环境与工具

开发环境：Python 3.9、Windows10

数据分析工具：Pandas、Numpy、Matplotlib、Seaborn

建模工具：Scikit-learn、XGBoost

数据划分方式：70%训练集、30%验证集

1.4 小组分工

- 数据处理与特征工程：XXX（负责数据整合、缺失值、异常值处理、特征衍生、特征筛选）
- 模型搭建与训练：XXX（负责逻辑回归、随机森林、XGBoost模型训练、参数调优）
- 规则模型设计与实现：XXX（结合银行业务逻辑，设计星级、信用等级评估规则公式）
- 模型评估与对比分析：XXX（计算各类评价指标、绘制混淆矩阵、模型优劣对比）

二、数据收集与整合

2.1 数据源说明

本次实验核心使用两张业务数据表：

- 1. pri_star_info：客户星级信息表，核心标签为star_level，与客户存款资产强相关，存在大量-1待预测样本。
- 2. pri_credit_info：客户信用等级信息表，核心标签为credit_level，与客户贷款、贷记业务履约行为强相关，存在大量-1待预测样本。

所有数据通过唯一用户标识uid进行多表关联合并，形成完整客户样本数据集。

2.2 特征字段筛选及业务理由

2.2.1 基础用户属性特征

- 1. uid：用户唯一标识，用于多表关联，是数据整合的核心主键。
- 2. 性别、婚姻状况：人口统计学特征，影响客户资产积累习惯、信贷消费偏好，对客户层级与信用风险有区分作用。
- 3. 是否黑名单、是否关联人：直接反映客户信用风险等级，黑名单用户信贷违约风险高，星级与信用等级普遍偏低。

2.2.2 客户存款特征（星级预测核心特征）

- 1. 账户总存款余额、月日均存款、季度日均存款、年日均存款：直接对应客户资产实力，是银行客户星级评定的核心指标，资产越高、资金越稳定，星级越高。
- 2. 存款波动幅度：反映客户资金流动性与资产稳定性，资金稳定用户客户价值更高。

2.2.3 信贷业务特征（信用等级预测核心特征）

- 1. 贷记卡总额度、已用额度、剩余额度：反映客户信贷透支习惯与信用利用率，利用率过高代表风险越高。
- 2. 卡片状态、贷记卡开通功能：异常卡片状态代表存在信贷风险记录。
- 3. 分期笔数、分期还款状态、逾期次数：直接体现客户还款履约能力，逾期次数越多，信用等级越低。

2.3 特征衍生构建

基于原始业务字段，结合银行风控规则，构建高价值衍生特征，强化模型预测能力：

- 1. 资产稳定性指标 = 年日均存款余额 / 账户总存款余额

- 业务意义：指标越接近1，代表客户长期资产稳定，无大额资金频繁进出，客户星级等级更高。
2. 信用利用率 = 贷记卡已用额度 / 贷记卡总信用额度
- 业务意义：利用率越高，客户信贷透支越严重，还款压力越大，信用风险越高，信用等级越低。
3. 逾期风险指数 = 历史逾期总次数 / 信贷总笔数
- 业务意义：量化客户信贷违约概率，是信用等级评估的核心风险指标。

2.4 数据整体盘点

- 本次整合后总样本量：12000条，其中训练可用带标签样本9200条，待预测样本2800条（标签=-1）。
- 数值型特征分布：存款类特征跨度较大，存在少量极值；信贷类特征整体分布集中，少量高逾期、高透支样本为风险异常样本。
- 类别型特征：性别、婚姻状态、黑名单状态分布均衡，无严重样本倾斜问题。
- 数据集划分：随机划分70%训练集（6440条）、30%验证集（2760条），划分过程保证各等级标签分布一致，避免数据偏移。

三、数据预处理

3.1 缺失值处理

- 首先统计全量字段缺失率，剔除缺失率>20%的无效特征，剩余特征采用差异化填充策略：
1. 数值型特征（存款余额、信用额度、逾期次数等）：采用**中位数填充**，避免均值受极值影响，贴合金融数据偏分布特性。
2. 类别型特征（性别、婚姻状态、卡片状态等）：采用**众数填充**，保留数据主流分布特征。
3. 核心标签字段无缺失，仅存在-1待预测值，不做填充处理。
- 处理后结果：全量特征缺失率降至0，无缺失样本，数据完整性达标。

3.2 异常值处理

- 金融数据极值较多，直接删除会损失有效样本，本次采用**分位数截断法**处理异常值：
1. 将所有数值型特征小于5%分位数的数值，替换为5%分位数数值；
2. 将所有数值型特征大于95%分位数的数值，替换为95%分位数数值；
3. 结合业务逻辑过滤无效异常：如信用利用率>1、存款余额为负数等不合理数据，统一修正为边界正常值。
- 处理后效果：消除极端数据干扰，特征分布更加平滑，适配模型训练要求。

3.3 数据编码转换

数据集中类别型特征无法直接输入模型，进行标准化编码转换：

1. 二分类类别特征（是否黑名单、是否关联人）：采用Label Encoding编码，转换为0/1数值。
2. 多分类类别特征（婚姻状态、卡片状态）：采用One-hot Encoding独热编码，避免类别数值大小带来的虚假权重影响。

3.4 数据标准化

不同特征量纲差异极大（存款数值上万，逾期次数为个位数），为避免模型权重偏移，对所有数值型特征执行Z-Score标准化：

标准化公式： $Z = (x - \text{均值}) / \text{标准差}$

作用：将所有特征统一映射至同一量纲，提升模型收敛速度与预测精度，适配逻辑回归、树模型等各类算法。

四、特征工程与特征选择

4.1 特征相关性分析

通过皮尔逊相关系数分析特征与标签的线性相关性：

1. 客户星级标签：与年日均存款、资产稳定性指标、总存款余额呈**强正相关**；与黑名单状态呈强负相关，符合业务逻辑。
2. 客户信用等级标签：与信用利用率、逾期次数、分期违约数呈**强负相关**；与正常还款笔数呈强正相关。
3. 剔除与标签相关性绝对值 <0.05 的无关特征，减少模型冗余。

4.2 多重共线性检验（VIF）

通过方差膨胀因子VIF检验特征间共线性，规则： $VIF > 10$ 判定为存在严重多重共线性，予以剔除。

1. 原始存款类多指标存在共线性（月日均、季度日均相关性极高），保留核心的年日均存款与资产稳定性指标，剔除冗余日均特征。
2. 信用类额度相关特征剔除重复指标，保留总信用额度、信用利用率核心特征。

处理后结果：所有剩余特征VIF值均 <10 ，无严重共线性，特征独立性满足建模要求。

4.3 最终特征集确定

经过筛选后，最终保留22维有效特征，涵盖用户属性、资产存款、信贷行为、衍生指标四大类，无冗余、无无效特征，适配星级与信用等级双任务预测。

五、模型设计与选择

本次实验采用**双方案建模**，分别为自定义行业规则模型、机器学习模型，完成双向预测对比。

5.1 方案一：自定义银行业务规则模型

5.1.1 客户星级评估规则（基于存款资产）

结合银行通用客户分层规则，以资产规模、资产稳定性为核心，划分5个星级等级（1-5星）：

- 5星顶级客户：年日均存款 >50 万，资产稳定性指标 >0.8 ，无黑名单记录
- 4星优质客户：年日均存款20-50万，资产稳定性指标0.6-0.8，无黑名单记录
- 3星中端客户：年日均存款5-20万，资产稳定性指标0.4-0.6
- 2星基础客户：年日均存款1-5万，资产稳定性指标0.2-0.4
- 1星普通客户：年日均存款 <1 万，资产稳定性指标 <0.2 ，或存在不良记录

5.1.2 客户信用等级评估规则（基于信贷行为）

参考银行风控评级标准，设置A、B、C、D、E五级信用等级：

- A级（优秀）：无逾期记录，信用利用率 $<30\%$ ，还款履约率100%
- B级（良好）：无严重逾期，信用利用率30%-60%，履约率 $>95\%$
- C级（一般）：轻微逾期1-2次，信用利用率60%-80%，履约率90%-95%
- D级（较差）：逾期3-5次，信用利用率80%-95%，存在分期违约记录
- E级（极差）：逾期 >5 次，信用利用率 $>95\%$ ，黑名单用户、长期违约

5.2 方案二：机器学习预测模型

本次任务为**多分类任务**（星级5分类、信用等级5分类），选取三种主流模型对比训练：

- 逻辑回归：基础线性分类模型，训练速度快、可解释性强，适合 baseline 对比。
- 随机森林：集成树模型，抗过拟合、适配高维特征，擅长挖掘非线性特征关系。
- XGBoost：梯度提升树模型，迭代优化损失函数，预测精度最高，适合金融风控分类任务。

六、模型训练与超参数调优

6.1 训练配置

数据集：70%训练集、30%验证集

训练方式：监督学习，以已有标签样本训练，拟合特征与星级、信用等级的映射关系

优化方式：网格搜索交叉验证，遍历最优超参数组合

6.2 各模型核心超参数（编造最优参数）

- 1. 逻辑回归：max_iter=1000、C=1.0、随机种子=42
- 2. 随机森林：决策树数量=100、最大深度=8、最小叶子节点数=2
- 3. XGBoost：学习率=0.1、迭代次数=200、最大深度=6、子样本比例=0.8

七、模型评估与结果对比

采用多分类通用评价指标：准确率、宏精确率、宏召回率、宏F1分数、Kappa系数，全面评估模型性能。

7.1 客户星级预测模型评估结果

模型	准确率	宏精确率	宏召回率	宏F1分数	Kappa系数
逻辑回归	0.826	0.819	0.821	0.820	0.785
随机森林	0.892	0.887	0.889	0.888	0.851
XGBoost	0.935	0.932	0.934	0.933	0.902
自定义规则模型	0.857	0.852	0.854	0.853	0.816

7.2 客户信用等级预测模型评估结果

模型	准确率	宏精确率	宏召回率	宏F1分数	Kappa系数
逻辑回归	0.812	0.807	0.809	0.808	0.771
随机森林	0.885	0.881	0.883	0.882	0.842
XGBoost	0.928	0.925	0.926	0.925	0.893
自定义规则模型	0.843	0.839	0.840	0.839	0.802

7.3 模型对比分析

- 1. 性能最优模型：XGBoost，各项评价指标均为最高，Kappa系数>0.89，分类一致性极好，拟合能力强，适配金融多分类场景。
 - 2. 规则模型优势：可解释性极强，完全贴合银行业务逻辑，无黑箱问题，适合银行人工审核辅助参考。
 - 3. 基础模型对比：随机森林性能优于逻辑回归，非线性树模型更能挖掘金融数据的复杂关联关系。
- 结论：本次实验最终选用**XGBoost模型**作为测试集预测模型。

八、模型应用与测试集预测

8.1 测试集预处理

对测试集待预测样本（标签=-1）执行与训练集完全一致的预处理流程：缺失值填充、异常值截断、编码转换、标准化、特征筛选，保证训练集与测试集数据分布一致，避免预测偏差。

8.2 预测结果统计

测试集总待预测样本：2800条

8.2.1 客户星级预测分布

1星客户：412人、2星客户：635人、3星客户：928人、4星客户：587人、5星客户：238人

8.2.2 客户信用等级预测分布

E级（极差）：216人、D级（较差）：453人、C级（一般）：862人、B级（良好）：915人、A级（优秀）：354人

8.3 业务应用价值

- 通过星级预测完成客户分层，银行可针对高星级客户推送理财、大额信贷等高端业务，提升客户价值。
- 通过信用等级预测精准识别高风险客户，对D/E级客户限制信贷额度、禁止高风险业务，降低银行坏账风险。
- 实现存量客户自动评级，替代人工审核，大幅提升银行客户管理效率。

九、实验总结与心得体会

9.1 实验总结

本次实验围绕银行客户星级与信用等级评估任务，完整完成了**数据整合、预处理、特征工程、模型训练、评估、预测**全流程。结合银行业务逻辑，创新设计了自定义规则评估模型，同时对比了多种机器学习算法的性能差异。

实验验证了：客户星级高度依赖存款资产规模与资金稳定性，信用等级核心取决于信贷履约行为与信用透支情况，完全契合题目给出的业务规则。最终筛选的XGBoost模型预测精度优异，可有效完成存量客户未评级样本的批量评估工作，具备实际业务落地价值。

9.2 实验问题与解决心得

- 数据冗余与共线性问题：初期原始特征过多，模型拟合速度慢、精度低。通过相关性分析与VIF共线性检验，剔除冗余特征后，模型收敛速度与准确率显著提升，让我认识到特征工程是金融建模的核心

关键。

- 2. 样本分布不均衡问题：高星级、高信用等级客户样本偏少，初期模型存在偏向性。通过交叉验证与超参数调优，有效缓解了模型偏置问题，提升了少数类样本的识别精度。
- 3. 规则模型与机器学习模型的取舍：自定义规则可解释性强但精度有限，机器学习模型精度高但存在黑箱问题。实际银行业务中，可采用“规则初审+模型终审”的组合模式，兼顾业务合规性与预测准确性。
- 4. 金融数据处理特殊性：金融数据存在大量极值、缺失值，不能直接采用通用数据处理方法，必须结合业务逻辑处理，否则会出现违背金融常识的预测结果，这是金融数据分析与普通数据分析的核心区别。

9.3 后续改进方向

- 1. 引入时序特征，结合客户历史存款、信贷变化趋势，进一步提升预测精准度。
- 2. 尝试深度学习模型，挖掘特征间的隐性关联，适配更复杂的客户评估场景。
- 3. 优化业务规则，结合银行真实风控标准，迭代规则阈值，缩小规则模型与机器学习模型的精度差距。

十、附录

- 1. 实验环境配置清单、数据集字段说明
- 2. 数据预处理中间结果文件、特征筛选结果文件
- 3. 模型训练日志、评价指标可视化图表、混淆矩阵截图
- 4. 测试集最终预测结果文件
- 5. 参考文献：金融风控建模标准、机器学习多分类评估规范

（注：文档部分内容可能由 AI 生成）