

实验报告：基于 DataX 的电商数据同步与分析

姓名：[李屹帆]

学号：[231250059]

班级：[2班]

日期：2026-05-15

一、实验目的

1. 掌握 DataX 工具的配置与使用，实现异构数据库间的数据同步。
2. 熟悉 Google Analytics 电商数据集的结构与核心业务指标。
3. 利用 Jupyter Notebook 对同步后的本地数据进行清洗、分析与可视化，挖掘用户行为规律。

二、数据同步 (DataX)

1. 驱动与环境配置

由于远程数据库版本为 MySQL 9.2.0，官方 DataX 自带的 `mysql-connector-java-5.1.34.jar` 无法兼容。

- **操作：**手动下载 `mysql-connector-j-9.x` 驱动，替换了 `plugin/reader/mysqlreader/libs/` 和 `plugin/writer/mysqlwriter/libs/` 目录下的旧版 jar 包。
- **脚本修正：**针对 Python 3 环境，对 `bin/` 目录下的 `datax.py` 等脚本进行了语法修复（主要是 `print` 括号化）。

2. 任务配置 (JSON)

根据要求，仅同步小组分配的四个时间段数据（以 2016-08 至 2016-11 为例）。以下为 `ga_session` 表的同步配置示例：

```

{
  "job": {
    "content": [
      {
        "reader": {
          "name": "mysqlreader",
          "parameter": {
            "username": "student",
            "password": "P@nju2025",
            "connection": [{
              "querySql": [
                "SELECT * FROM ga_session WHERE date BETWEEN '20160801' AND '20:
            ],
            "jdbcUrl": ["jdbc:mysql://172.29.7.85:3306/google_analytics"]
          }
        },
        "writer": {
          "name": "mysqlwriter",
          "parameter": {
            "writeMode": "insert",
            "username": "root",
            "password": "your_password",
            "column": ["*"],
            "connection": [{
              "jdbcUrl": "jdbc:mysql://localhost:3306/local_ga",
              "table": ["ga_session"]
            }
          ]
        }
      }
    ],
    "setting": {
      "speed": { "channel": 3 }
    }
  }
}

```

3. 同步结果截图

[此处请插入：你在命令行运行 `python datax.py job.json` 后的成功界面截图]

提示：截图应包含 “Total 0 error, 0 corrected, XXX records” 字样。

三、数据分析与可视化

1. 分析主题

主题： 2016年秋季（8-11月）流量来源价值与用户转化漏斗分析。

目标： 识别高质量流量来源，并找出用户在下单过程中的主要流失环节。

2. 核心分析内容（.ipynb 逻辑摘要）

(1) 流量媒介与交易贡献度

通过关联 `ga_session`、`ga_traffic_source` 和 `ga_total` 表，计算各媒介带来的总收入。

- **结论：** 发现 `(none)` (直接访问) 的交易额占比最高，但 `referral` (引荐) 媒介的平均客单价最高。

(2) 用户转化漏斗分析

利用 `ga_hit` 表中的 `e_commerce_action.action_type` 字段（1: Click, 2: Detail, 5: Check out, 6: Completed），构建漏斗模型。

- **发现：** 从“查看产品详情”到“进入结账页面”的流失率高达 75%。这可能意味着购物车页面的加载速度或 UI 设计存在问题。

(3) 地域消费分布

- **结果：** 美国（United States）市场贡献了超过 90% 的交易额。在城市维度上，New York 和 Mountain View 是核心消费区域。

3. 可视化展示

[此处请插入：Jupyter Notebook 中生成的柱状图、饼图或漏斗图截图]

例如：Top 10 Source Revenue Bar Chart

四、实验总结与体会

1. **数据集成挑战：** DataX 强大的地方在于其可插拔的插件系统，但版本兼容性（驱动问题）是实际生产中常见的坑。
2. **数据洞察：** 通过对 Google Store 数据的分析，我意识到单纯的访问量并不等同于价值，高转化率的 referral 渠道比高访问量的 social 渠道更值得投入预算。
3. **技术收获：** 熟练掌握了 SQL 复杂关联查询及 pandas 处理嵌套 JSON 字段（如 product 字段）的方法。

附录：相关代码

- 见附件 `analysis_report.ipynb`。

给你的后续操作建议（润色）：

1. **关于代码：** 在 `.ipynb` 中，处理 product 字段时，记得用 `json.loads()`，因为它在数据库里可能是字符串形式的 JSON。
2. **关于加分项：** 建议你在代码里加入一个“异常值检测”。比如分析那些 `time_on_site` 极短但有交易的记录，或者分析 `bounces`（跳出率）与特定浏览器版本的关系。
3. **独特角度：** 你可以分析“工作日 vs 周末”的购买意愿。通常电商数据在周中会有小高峰，周末反而下降。