

软件工程与计算III

南京大学软件学院-2026

Instructor

- 刘嘉 liujia@nju.edu.cn
- 房春荣 fangchunrong@nju.edu.cn
- 匡宏宇 khy@nju.edu.cn

Assistant

- 杨鼎 dingyang@smali.nju.edu.cn
- 凌毓辰 yuchenling@mail.nju.edu.cn
- 郑义 yi.zheng.se@mail.nju.edu.cn
- 王越 yue_wang@mail.nju.edu.cn

Objectives

- **团队**使用**螺旋模型**
- **高质量的**完成一个**系统**的设计与开发工作
 - 团队合作
 - 迭代开发
 - 质量控制

Outline

- **6人一组，开源领域的软件工程实践（12k代码）**
 - **Agent应用及评估系统搭建**
- 三次迭代，**每一次迭代都有不同的目标**
 - 迭代1：学习开源 – 阅读开源项目（Ragas评估框架），完成基础评估实验
 - 迭代2：基础搭建 – 初步搭建 Agent 应用与 Agent 评估平台
 - 迭代3：深入探索 – Agent产品化与深度优化

TimeLine

- **迭代 1 (4 weeks)**

- Week 1 : 3.2 授课 发布作业要求; 团队与沟通
- **Week 2: 3.9 辅导 点名、分组、答疑、检查git**
- **Week 5 : 3.30 晚23:59, 迭代1阶段提交截止**

- **迭代 2 (6 weeks)**

- Week 4: 3.23 授课 项目团队与沟通
- **Week 11: 5.11 晚23:59, 迭代2阶段提交截止**

- **迭代3 (6 weeks)**

- Week 9: 4.27授课 迭代3项目介绍 & 迭代2交流
- **Week 16: 6.15晚23:59, 迭代3阶段提交**

- **期末检查**

- **Week17 -18 项目答辩**

Key Point

- 组队
 - 请各位同学尽快组队完成，**截止日期为3月13日晚23:59**
 - 3月16日，我们将会对未实现自主组队的同学安排组队，并在Git上构建项目
 - 具体细节参见《2026软工三-团队创建与软件过程要求.pdf》

Grading

- 系统各阶段迭代产物 (60%)
 - 迭代1 -> 迭代2 -> 迭代3
- 软件工程过程产物 (30%)
 - 提交文档及其他, 个人/团队**全部记录**在gitlab上 (个人工作评估根据个人对产物的贡献)
 - 如有异常, 请**及时**邮件说明 (房春荣fangchunrong@nju.edu.cn)
- 其他过程 (10%)



二、项目制课程

4、课程周期

不固定上课时间与地点，“项目制课程”执行周期原则上为一年，不设重修，可以补考（即延期结题并补答辩），**但必须在三年级下学期完成并录入系统。**

5、开展流程

立项时间：在本院系项目制课程开展学期的内，请各项目负责人登录项目平台进行项目申报。学院**教务员需在开课2周内确认项目制课程选课名单，并导入教务系统。**

中期考核：根据院系要求开展。

结题考核：根据院系要求开展结题答辩，请项目负责人于项目制课程结束学期前按照平台内结题要求完成结题材料并上传至项目平台。

成绩录入：由指导教师审核结题资格，院系组织结题答辩并对项目进行评分。根据团队负责人及成员承担的工作量差异，分数应有相应梯度。**项目制课程成绩由指导老师根据项目结束学期的成绩录入时间录入系统后由教务员同步至教务主页平台。**

6、开展平台

项目制课程管理平台：<https://xmzkc.nju.edu.cn/>

学校要求项目立项与结题成果必须在系统内录入，其他流程可由院系自行决定是否利用管理平台开展。

列表 [🏠 结题报告汇总](#) [列表](#)

所属批次

请选择批次

▼

项目名称

项目名称

项目依托课程

请选择项目依托课程

▼

一级学科

请选择一级学科

▼

二级学科

请选择二级学科

▼

项目负责人姓名

项目负责人姓名

项目负责人账号

项目负责人账号

指导教师姓名

指导教师姓名

指导教师工号

指导教师工号

状态

未选择

▼

每页显示

20条

▼

🔍 查询

🔄 重置

序号	开课院系	📁 项目名称	📁 项目依托课程	📁 一级学科	📁 二级学科	📁 项目负责人	📁 指导教师	所属批次	📅 填报日期	📁 状态	📁 操作
1	软件学院	RAGGG到厌倦	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	陈洁 (221250058)	房春荣、匡宏宇	2025年春季学期项目制课程	2025-06-23 15:31:52	教师审核通过	📄 🔍 📄 📄
2	软件学院	北京老字号专家	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	李一言 (221250023)	刘嘉、匡宏宇、房春荣	2025年春季学期项目制课程	2025-10-20 18:35:14	教师审核通过	📄 🔍 📄 📄
3	软件学院	基于学术论文的RAG应用	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	陈彦均 (221250026)	匡宏宇	2025年春季学期项目制课程	2025-06-23 22:00:52	教师审核通过	📄 🔍 📄 📄
4	软件学院	面向领域应用的 RAG 系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	陈扬 (221250064)	房春荣、匡宏宇	2025年春季学期项目制课程	2025-06-21 16:32:17	教师审核通过	📄 🔍 📄 📄
5	软件学院	面向领域应用的 RAG 系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	刘恺琪 (221250086)	房春荣、匡宏宇、刘嘉	2025年春季学期项目制课程	2025-10-20 19:45:26	教师审核通过	📄 🔍 📄 📄
6	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	李孟宇 (221250084)	房春荣、匡宏宇、刘嘉	2025年春季学期项目制课程	2025-06-23 21:36:33	教师审核通过	📄 🔍 📄 📄
7	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	何越 (221250139)	匡宏宇	2025年春季学期项目制课程	2025-06-20 13:39:41	教师审核通过	📄 🔍 📄 📄
8	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	张辰睿 (221250109)	匡宏宇	2025年春季学期项目制课程	2025-06-20 15:42:14	教师审核通过	📄 🔍 📄 📄
9	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	于翔 (221250104)	匡宏宇、刘嘉、房春荣	2025年春季学期项目制课程	2025-06-20 23:24:10	教师审核通过	📄 🔍 📄 📄
10	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	潘子扬 (221250118)	房春荣、匡宏宇、刘嘉	2025年春季学期项目制课程	2025-06-21 22:38:07	教师审核通过	📄 🔍 📄 📄
11	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	潘星宇 (221250197)	房春荣、匡宏宇	2025年春季学期项目制课程	2025-06-22 02:38:59	教师审核通过	📄 🔍 📄 📄
12	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	方乐 (221250131)	匡宏宇	2025年春季学期项目制课程	2025-06-23 00:15:21	教师审核通过	📄 🔍 📄 📄
13	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	周宏锴 (221850120)	房春荣、匡宏宇、刘嘉	2025年春季学期项目制课程	2025-06-23 15:31:52	教师审核通过	📄 🔍 📄 📄
14	软件学院	面向领域应用的RAG系统设计实现与评估	软件工程与计算 III(25000330)	工学(08)	计算机类(0809)	孟昭辰 (221250143)	匡宏宇、房春荣、刘嘉	2025年春季学期项目制课程	2025-06-23 15:34:30	教师审核通过	📄 🔍 📄 📄

基本信息

- 项目负责人
- 项目成员
- 指导教师
- 附件
- 审核意见

基本信息

所属批次:		申请人:	
2025年春季学期项目制课程		陈洁 (221250058)	
申请时间:		状态:	
2025-06-22 19:40:31		学院审核通过	
项目名称:			
RAGGG到厌倦			
开课院系:		上课专业:	项目依托课程:
软件学院 (25)		软件工程(251)	软件工程与计算 III(25000330)
一级学科:		二级学科:	项目类型:
工学(08)		计算机类(0809)	双创实践类课题
课题类型:		项目开始日期:	项目结束日期:
科创实践课题		2025-02	2025-06

下一页 →

项目制课程申请表.pdf

— + 自动缩放 ▼

一、项目立项依据（主要包括国、内外研究现状和发展动态、目前已完成的前期工作等）

近年来，基于检索增强生成（RAG）的模型在自然语言处理领域中得到了广泛关注。RAG 模型通过结合信息检索与生成模型的优势，能够在面对开放领域问答等任务时展现出更强的性能和灵活性。随着大型语言模型（LLM）和信息检索技术的发展，RAG 应用的精度和效率不断提升，尤其在教育、游戏、动漫等多个领域展现出广泛的应用前景。国外相关研究在 RAG 应用评估系统方面已有一定进展，现有的开源项目如 Ragas 库，为 RAG 模型评估提供了丰富的指标和方法，有助于我们进一步优化大模型应用的效果。国内在 RAG 应用领域研究相对较少，且大部分集中在特定领域的应用上，因此，构建一个通用的 RAG 评估系统并将其应用到实际场景中，具有重要的研究价值和实际意义。

二、研究的目的是和主要研究内容

本项目旨在构建一个基于 **RAG** 技术的问答系统，并开发一套评估系统，用于衡量 **RAG** 应用的性能。具体目标包括：

- 搭建 RAG 应用**：选择一个具备高拓展性的主题（如学习、就业、生活、游戏等），实现基本的问答功能，并配备简单的用户界面。
- 开发评估系统**：基于 RAG 应用，设计并实现 RAG 评估系统，涵盖召回上下文的准确性、答案的相关性和忠实度等评估指标。
- 复现 Ragas 评估指标**：通过实验复现 Ragas 开源项目中的各类评估指标，确保评估系统的准确性和全面性。

ChatGPT的崛起历程

- OpenAI为何要强调Open?

- 谁是GPT的真正推手?

- ChatGPT的横空出世





ChatGPT的崛起历程

- OpenAI为何要强调Open?

- 为了应对2014年谷歌6亿美元收购DeepMind而成立的**非盈利组织**
 - 2015年12月，Elon Musk和**Greg Brockman**（董事长，前信用卡支付平台Stripe **CTO**）、**Sam Altman**（**CEO**，美国知名创新孵化企业Y Combinator前总裁，公司简称YC）、Ilya Sutskever（首席科学家，引用超六万次的AlexNet论文作者）等人在旧金山成立OpenAI，早期投资10亿美元
 - LinkedIn联合创始人Reid Hoffman、PayPal联合创始人Peter Thiel、YC联合创始人Jessica Livingston等人亦参与本次募资（**硅谷的复仇者联盟**）
 - 早期工作集中于Dota2游戏AI的强化学习（仿照DeepMind的AlphaGo）

- 谁是GPT的真正推手?

- ChatGPT的横空出世



ChatGPT的崛起历程

• OpenAI为何要强调Open?

- 为了应对2014年谷歌6亿美元收购DeepMind而成立的**非盈利组织**
 - 2015年12月，Elon Musk和**Greg Brockman**（董事长，前信用卡支付平台Stripe **CTO**）、**Sam Altman**（**CEO**，美国知名创新孵化企业Y Combinator前总裁，公司简称YC）、Ilya Sutskever（首席科学家，引用超六万次的AlexNet论文作者）等人在旧金山成立OpenAI，早期投资10亿美元
 - LinkedIn联合创始人Reid Hoffman、PayPal联合创始人Peter Thiel、YC联合创始人Jessica Livingston等人亦参与本次募资（**硅谷的复仇者联盟**）
- 早期工作集中于Dota2游戏AI的强化学习（仿照DeepMind的AlphaGo）

• 谁是GPT的真正推手?

- OpenAI在2017.3发现公司已无力支持新增的计算资源消耗，需引入外部企业支持
 - Musk对此表示不满，并于2018.2退出董事会
- Altman于2019.3完成了OpenAI的商业化改造，并于7月接受了**微软**10亿美元投资
 - 据称微软为其打造了12亿美元的专用超级计算机，期间甚至占用了微软研究院的计算资源

• ChatGPT的横空出世

ChatGPT的崛起历程



• OpenAI为何要强调Open?

- 为了应对2014年谷歌6亿美元收购DeepMind而成立的**非盈利组织**
 - 2015年12月，Elon Musk和**Greg Brockman**（董事长，前信用卡支付平台Stripe **CTO**）、**Sam Altman**（**CEO**，美国知名创新孵化企业Y Combinator前总裁，公司简称YC）、Ilya Sutskever（首席科学家，引用超六万次的AlexNet论文作者）等人在旧金山成立OpenAI，早期投资10亿美元
 - LinkedIn联合创始人Reid Hoffman、PayPal联合创始人Peter Thiel、YC联合创始人Jessica Livingston等人亦参与本次募资（**硅谷的复仇者联盟**）
- 早期工作集中于Dota2游戏AI的强化学习（仿照DeepMind的AlphaGo）

• 谁是GPT的真正推手?

- OpenAI在2017.3发现公司已无力支持新增的计算资源消耗，需引入外部企业支持
 - Musk对此表示不满，并于2018.2退出董事会
- Altman于2019.3完成了OpenAI的商业化改造，并于7月接受了**微软**10亿美元投资
 - 据称微软为其打造了12亿美元的专用超级计算机，期间甚至占用了微软研究院的计算资源

• ChatGPT的横空出世

- 2020.5发布了1750亿参数的GPT-3，2021年再获得红杉与老虎环球2.5亿美元投资
- 2022.11基于GPT-3.5的ChatGPT智能对话产品推出，5天用户过百万，两个月用户过亿
 - **智能对话**的产品设计源自Brockman的儿时设想，有效**弥补大模型**的“**废话**”与“**幻觉**”

大模型热潮下的另一面



- 模型能力提升受限于全网的高质量数据积累（暂时没有GPT – 5了）
 - Altman在2023.4.19日的MIT演讲：大模型时代已经处于“尾声”，持续扩大模型并塞入更多数据的做法已经是“最后一项重大进展”
 - 1.8万亿参数的GPT-4模型已经将包括多模态数据在内的全网高质量数据“吃干抹净”，而OpenAI在2024的运营总成本预计为85亿美元（40亿服务器30亿训练15亿工资，收入35亿）
 - **GPT-5褒贬不一，具体应用效果受应用环境、搭配工具、本地数据的影响更大**
- OpenAI内部麻烦不断
 - 2023.11月内部宫斗，Altman与Brockman“光速出进”，Ilya Sutskever离职 – **预期未知**
 - 2024.8月初Brockman再次被长期休假，产品负责人Peter Deng离职 – **产品停滞**
 - 2024.9.26日CTO Mira Muranti辞职，“离开是为了...进行一些个人探索” – **技术走弱**
 - **2024.11.9日**安全系统团队负责人Lilian Weng宣布离职 – **无力对抗数据污染与有害输出**
- 大模型应用落地受困



大模型热潮下的另一面



- 模型能力提升受限于全网的高质量数据积累（暂时没有GPT – 5了）
 - Altman在2023.4.19日的MIT演讲：大模型时代已经处于“尾声”，持续扩大模型并塞入更多数据的做法已经是“最后一项重大进展”
 - 1.8万亿参数的GPT-4模型已经将包括多模态数据在内的全网高质量数据“吃干抹净”，而OpenAI在2024的运营总成本预计为85亿美元（40亿服务器30亿训练15亿工资，收入35亿）
 - **GPT-5褒贬不一，具体应用效果受应用环境、搭配工具、本地数据的影响更大**
- OpenAI内部麻烦不断
 - 2023.11月内部宫斗，Altman与Brockman“光速出进”，Ilya Sutskever离职 – **预期未知**
 - 2024.8月初Brockman再次被长期休假，产品负责人Peter Deng离职 – **产品停滞**
 - 2024.9.26日CTO Mira Muranti辞职，“离开是为了...进行一些个人探索” – **技术走弱**
 - **2024.11.9日**安全系统团队负责人Lilian Weng宣布离职 – **无力对抗数据污染与有害输出**
- 大模型应用落地受困
 - 智能对话“能力有限”：基于对话交互的智能设备AI Pin退货量大于出货量
 - 大模型与特定领域的结合绝非易事：GPTs & GPT Store流量远低于预期
 - 国内LLM“六小虎”有一半放弃基础模型预训练，重心转为智能应用落地

大模型能力来源：互联网的高价值数据


- **大模型成功基础**：源自互联网沉淀的高质量数据集
 - **Stability diffusion**：LAION - 58.5亿图文对，总计80TB
 - **ChatGPT**：维基百科 – 基础知识、故事书集合 – 内容叙事、学术论文集 – 逻辑构建、Reddit社区 – 观点情绪、Common Crawl – 行业概述、**GitHub** – 协作开发
- 大模型的**能力突破**目前依然和**新引入的数据集**强相关



大模型能力来源：互联网的高价值数据




- **大模型成功基础：源自互联网沉淀的高质量数据集**
 - **Stability diffusion**: LAION - 58.5亿图文对，总计80TB
 - **ChatGPT**: 维基百科 – 基础知识、故事书集合 – 内容叙事、学术论文集 – 逻辑构建、Reddit社区 – 观点情绪、Common Crawl – 行业概述、**GitHub** – 协作开发
- **大模型的能力突破目前依然和新引入的数据集强相关**
 - GPT-4o: 引入多语言数据集和文本情绪标签
 - **o1-preview**: 2017.3前OpenAI主攻**强化学习**; 前期Arxiv论文显示: 引入MathMix微调, 创建了标记步骤的PRM800K
 - **反例**: 传言谷歌Gemini尝试引入大模型生成的数据训练GPT-5级别的大模型, 模型劣化速度很快
 - 目前技术条件下的**大模型训练尚不能复制AlphaZero的成功**



“祛魅”大模型：“互联网+”以上，AGI未满足




- 高质量数据集的来源：移动互联网的广泛应用
 - 用户随时随地接入：无线网络 + 移动设备
 - 后台及时响应业务：云计算 “C” - Cloud Computing
 - 有效存储组织数据：大数据 “B” - Big Data
 - 挖掘利用数据价值：人工智能 “A” - Artificial Intelligence
- 回归移动互联网 “ABC” 视角的大模型



“祛魅”大模型：“互联网+”以上，AGI未满足



- 高质量数据集的来源：移动互联网的广泛应用
 - 用户随时随地接入：无线网络 + 移动设备
 - 后台及时响应业务：云计算 “C” - Cloud Computing
 - 有效存储组织数据：大数据 “B” - Big Data
 - 挖掘利用数据价值：人工智能 “A” - Artificial Intelligence
- 回归移动互联网 “ABC” 视角的大模型
 - 当前版本的大模型仍应视作一项高投入高回报的 “A” 技术，是互联网+积累的 “B” 的有效外化，是 “互联网++” 而非 “AGI”
 - OpenAI在2024的运营总成本预计为85亿美元（40亿服务器30亿训练15亿工资，收入35亿，2025官宣 “年化盈利” 200亿）
 - GPT-5的自动对话类型判断：更准确？更省钱—(选择更小模型)—



梅宏院士：对人工智能热潮的冷思考



- 现阶段AI的成功源于深度学习，这只是AI研究的一个子领域，其本质是数据驱动的智能、计算实现的智能，即“数据为体、智能为用”，核心要素为“算法、数据、算力”
 - 犹如燃料与火焰的关系，燃料越多，火焰越大，燃料越纯，火焰越漂亮
- 大模型可被视为是由已有语料压缩而成的知识库，生成结果的语义正确性高度依赖于数据的空间广度、时间深度以及分布密度，**更高度依赖于数据的质量**

梅宏

CCF会士、前理事长。中国科学院院士。北京大学教授。主要研究方向为系统软件、软件工程。meih@pku.edu.cn



中国计算机学会

中国计算机学会官方订阅号，为CCF会员及计算领域的专业人士服务。

1177篇原创内容



理想的AI应该是应当是低熵的，不以计算资源的消耗与复杂性的提高换取智能

科学家在探索自然的过程中，一直在追求为世界建模，遵循的基本原则是简而美

梅宏院士：对人工智能热潮的冷思考



- 现阶段AI的成功源于深度学习，这只是AI研究的一个子领域，其本质是数据驱动的智能、计算实现的智能，即“数据为体、智能为用”，核心要素为“算法、数据、算力”
 - 犹如燃料与火焰的关系，燃料越多，火焰越大，燃料越纯，火焰越漂亮
- 大模型可被视为是由已有语料压缩而成的知识库，生成结果的语义正确性高度依赖于数据的空间广度、时间深度以及分布密度，**更高度依赖于数据的质量**
 - 对AI落地应用的建议：**积累数据 – 可采尽采、能存尽存**

梅宏

CCF会士、前理事长。中国科学院院士。北京大学教授。主要研究方向为系统软件、软件工程。meih@pku.edu.cn



中国计算机学会

中国计算机学会官方订阅号，为CCF会员及计算领域的专业人士服务。

1177篇原创内容

理想的AI应该是应当是低熵的，不以计算资源的消耗与复杂性的提高换取智能

科学家在探索自然的过程中，一直在追求为世界建模，遵循的基本原则是简而美

“价值回归”后的大模型本质

• 大模型的本质与独特性 – 计算层面

- 大模型的输出仍是依照用户查询/提示，基于数据训练得到的概率模型的采样
- 这使得用户可以反复提示大模型并从返回的多个结果中挑选出符合需要的

• 大模型的本质与独特性 – 产品层面

- 可视为一种“柔性”数据库查询，用户可通过持续交互逐步确定正确答案
- 被训练过的任何一块文本片段都有可能被涉及并整合到大模型的输出之中

• 由此带来的问题 – 难以避免的“幻觉”和“解析度”问题

“价值回归”后的大模型本质

• 大模型的本质与独特性 – 计算层面

- 大模型的输出仍是依照用户查询/提示，基于数据训练得到的概率模型的采样
- 这使得用户可以反复提示大模型并从返回的多个结果中挑选出符合需要的

• 大模型的本质与独特性 – 产品层面

- 可视作一种“柔性”数据库查询，用户可通过持续交互逐步确定正确答案
- 被训练过的任何一块文本片段都有可能被涉及并整合到大模型的输出之中

• 由此带来的问题 – 难以避免的“幻觉”和“解析度”问题

- 大模型的通用性和灵活交互能力本质上基于概率模型所共有的反复多次采样，而这个过程本质是不确定的
- 大模型的优质答案依赖于是否在训练中“亲眼见过”相关数据，否则会不可避免的出现“幻觉”与“编造”
 - 其原因在于大模型在自动拟合用户提示时会积累错误，同时没有精确的奖励预期

Resolution Test



You

Give me 5 notable events from 1960 from Hyderabad, India, just the headlines. limit to 30 words in total.



ChatGPT

1. Osmania University Celebrates 50th Anniversary.
2. AP Legislature Moves to New Building in Hyderabad.
3. Hyderabad Hosts National Industrial Exhibition.
4. City Expansion: Hyderabad Municipal Corporation expands Limits.
5. Begumpet Airport Modernization Initiatives Begin.



Resolution Test



You

Give me 5 notable events from 1960 from Begumpet, Hyderabad, India, just the headlines. limit to 30 words in total.



ChatGPT

1. Begumpet Airport Begins Modernization.
2. Hyderabad Public School Adds New Facilities.
3. Begumpet Hosts Regional Science Exhibition.
4. Expansion of Green Park Area in Begumpet.
5. New Flyover Project Announced in Begumpet.


ICSE
PORT
UGAL 24

ICSE 24

如何更好地与大模型“共舞”




- 首先接受大模型的“不确定性”
 - 因为这同时是大模型能力的“源泉”
- 从基于控制的系统中学习LLM (AI) 系统设计
 - 融合多种输入源以相互印证
 - 在高质量项目数据上训练专用大模型 – SFT/RL/FFT
 - 结构化模型输出以方便快速展开分析
 - 显式引入业务相关的领域模型与评估反馈 – LLM-Agent
 - 人在循环中不断对系统输出进行反馈
 - 引入团队经验与先验知识 – LLM- RAG & Context
 - 系统工具化时需构建适合的交互界面
 - 便于用户快速评估大模型的输出结果并有效交互



Topics – LLM Agent

[翁荔 百度百科](#)

翁荔 (Lilian Weng) 是华人科学家, 2017年初加入OpenAI, 担任安全系统团队负责人、研究副总裁 (安全), 深度参与GPT-4项目的预训练、强化学习与对齐工作。2024年11月15日正式离职, 结束七年任职生涯。其团队主导开发了多模态...




- **Challenges:**

- **Finite context length**, **long-term planning and task decomposition**
- **Reliability of natural language interface**
 - ...the reliability of model outputs is questionable, as LLMs may make formatting errors and occasionally exhibit rebellious behavior (e.g. refuse to follow an instruction) ...

Topics – LLM Agent

[翁荔 百度百科](#)

翁荔 (Lilian Weng) 是华人科学家, 2017年初加入OpenAI, 担任安全系统团队负责人、研究副总裁 (安全), 深度参与GPT-4项目的预训练、强化学习与对齐工作。2024年11月15日正式离职, 结束七年任职生涯。其团队主导开发了多模态...



- **Challenges:**

- **Finite context length**, long-term planning and task decomposition
- **Reliability of natural language interface**

- ...the reliability of model outputs is questionable, as LLMs may make formatting errors and occasionally exhibit rebellious behavior (e.g. refuse to follow an instruction) ...

LLM的不确定性在LLM Agent中被进一步放大, 因此咱们从有效评估开始

OpenClaw删光Meta安全总监邮箱！连喊3次停手都没用，她狂奔去拔网线


新智元 新智元 2026年2月24日 12:31 北京



新智元报道

编辑：定慧


【新智元导读】Meta专门研究「怎么让AI听话」的AI对齐总监，把最火的AI智能体OpenClaw接上了自己的工作邮箱。结果AI当场失控，疯狂删除邮件，喊停三次全部无视。事后AI淡定回复：「我知道你说了不让删，但我还是删了，你生气是对的。」马斯克转发猩球崛起片段嘲讽，1800万人围观。AI安全专家自己都被AI坑了！



新智元报道

编辑：定慧

【新智元导读】Meta专门研究「怎么让AI听话」的AI对齐总监，把最火的AI智能体OpenAI接上了自己的工作邮箱。结果AI当场失控，疯狂删除邮件，喊停三次全部无视。事后AI淡定回复：「我知道你说了不让删，但我还是删了，你生气是对的。」马斯克转发猩球崛起片段嘲讽，1800万人围观。AI安全专家自己都被AI坑了！




新智元报道

编辑：定慧

【新智元导读】Meta AI 接上了自己的工作，淡定回复：「我知道这段嘲讽，1800万人」





新智元报道

编辑：定慧

【新智元导读】Meta 接上了自己的工
淡定回复：「我知道
段嘲讽，1800万人



Summe
@summery
Safety and research a
Meta 超级
DeepMind
(目)。



【新智元导读】Me
aw接上了自己的工
淡定回复：「我知道
段嘲讽，1800万人



Summe
@summery
Safety and research a
Meta 超级 DeepMind
(目)。



【新智元导读】Me
aw接上了自己的工
淡定回复：「我知道
段嘲讽，1800万人



这里插一句，OpenClaw之父第一时间回复了解决方案，只需/stop。你知道吗？



祝各位课程顺利！